
DETECCIÓN DE ESTRÉS EN EEG MEDIANTE ALGORITMO SVM Y REPRESENTACIONES ESPECTRALES

Autores:

Cristian Jesús Echejaya Moreno (cristian.echajaya@unmsm.edu.pe)
Yarol Sebastian Nolasco Guia (yarol.nolasco@unmsm.edu.pe)

Asesores:

Ing. Sergio Renato Rengifo Lozano (P880301324@unitru.edu.pe)
Bach. Alfredo Lapoint Angulo (alfredo.lapoint@unmsm.edu.pe)

Universidad Nacional Mayor de San Marcos

Facultad de Ingeniería Electrónica

Dirección: Av. Carlos Germán Amezaga 375, Cercado de Lima, Perú.

Teléfono: (01) 619-7000 Anexo: 4203

Correo: eapiefiee@unmsm.edu.pe

Resumen

El estrés es una respuesta fisiológica esencial que, bajo condiciones prolongadas, puede convertirse en un riesgo significativo para la salud mental y física. En vista de las limitaciones asociadas a los métodos tradicionales de evaluación, surge la necesidad de implementar sistemas automáticos, objetivos y reproducibles que permitan detectar el estrés de manera precisa. Este estudio propone el diseño e implementación de un clasificador basado en máquinas de vectores de soporte (SVM) para identificar estados binarios de estrés y relajación a partir de señales EEG. La metodología contempla un pipeline riguroso de preprocesamiento, descomposición multiresolución mediante la Transformada Wavelet Discreta, análisis espectral con PSD, y extracción de características estadísticas. A fin de preservar la naturaleza no lineal y no estacionaria de las señales EEG, se emplean técnicas que minimizan la pérdida de información fisiológica relevante. Se espera que los resultados contribuyan a validar la viabilidad de modelos SVM como herramienta de apoyo diagnóstico en contextos clínicos y tecnológicos, manteniendo altos niveles de precisión sin comprometer la integridad de los datos neuronales.

Palabras clave: estrés, señales EEG, SVM, PSD, clasificación automática

Introducción

El estrés ha sido definido por la Organización Mundial de la Salud (OMS) como un estado de preocupación o tensión mental originado por situaciones difíciles [1]. Aunque constituye una respuesta adaptativa del organismo frente a desafíos o amenazas, su manifestación prolongada o desregulada se ha consolidado como un problema relevante de salud pública, dada su alta prevalencia y el impacto negativo sobre el bienestar físico y psicológico de los individuos.

Esta creciente relevancia como fenómeno clínico ha puesto de manifiesto las limitaciones de los métodos tradicionales de evaluación, que dependen principalmente de autorreportes subjetivos y observaciones clínicas susceptibles a sesgos interpretativos. En este contexto, la necesidad de establecer métodos de evaluación más objetivos y estandarizados ha motivado diversas investigaciones, como los estudios preliminares desarrollados por [2], que resaltan la importancia de herramientas reproducibles para la detección precisa del estrés.

A partir de este enfoque, investigaciones recientes como la de [3] han recurrido a técnicas de bioingeniería para identificar estados de estrés a partir del análisis de bioseñales, particularmente las señales electroencefalográficas (EEG). Estas señales, al ser procesadas mediante métodos matemáticos avanzados y modelos de inteligencia artificial, permiten desarrollar sistemas de clasificación capaces de discriminar entre estados estresados y no estresados. Entre los algoritmos de aprendizaje automático más empleados en este campo se encuentran K-Nearest Neighbors (KNN), regresión logística, máquinas de vectores de soporte (SVM) y Random Forest [4].

Planteamiento de Estudio

Aunque diversos enfoques han mostrado resultados prometedores al aplicar técnicas de procesamiento de señales combinadas con marcos híbridos de aprendizaje automático para clasificar el estado estrés de los sujetos [5], su aplicación clínica aún presenta limitaciones. En particular, para ser considerados viables en entornos clínicos reales, estos modelos deben alcanzar niveles de precisión superiores al 95 % con márgenes de error inferiores al 5 % [6].

En el estudio de [7], se entrena una máquina de vectores de soporte (SVM) utilizando, como parte de su metodología, un criterio de "aumento de data" con el objetivo de mitigar la influencia de valores atípicos presentes en el conjunto de datos EEG. Esta técnica consiste en ampliar las muestras originales escalando señales artificiales mediante factores preseleccionados cercanos a la unidad. No obstante, según [8], esta estrategia puede inducir sesgos en el conjunto de datos, comprometiendo así la veracidad de las métricas de precisión del clasificador SVM.

Este reto evidencia la necesidad de seguir desarrollando metodologías que no solo optimicen el rendimiento de clasificación, sino que además respeten la complejidad inherente de las bioseñales cerebrales, caracterizadas por su comportamiento altamente estocástico y no estacionario.

Problema de investigación

¿Cómo implementar un clasificador SVM que detecte de forma precisa el estrés a partir de señales EEG, sin alterar su complejidad no lineal y no estacionaria?

Justificación

Clínica

Desde una perspectiva clínica, el diagnóstico del estrés requiere métodos más objetivos que los cuestionarios tradicionales, los cuales pueden ser subjetivos e inconsistentes. El uso de señales EEG permite acceder a información fisiológica directa del estado cerebral, ofreciendo una vía más confiable y cuantificable para la detección del estrés.

Técnica

Desde una perspectiva técnica, las señales EEG poseen una complejidad considerable debido a su naturaleza no lineal, estocástica y no estacionaria. Esta estructura demanda el uso de clasificadores robustos que sean capaces de preservar dichas propiedades durante el procesamiento. En este contexto, las Máquinas de Vectores de Soporte (SVM) resultan especialmente adecuadas por su capacidad para manejar datos de alta dimensionalidad y realizar clasificaciones precisas incluso con volúmenes de datos moderados.

Objetivo General

Implementar y evaluar un clasificador SVM para detectar estrés a partir de señales EEG, respetando la complejidad propia de dichas señales y maximizando la precisión del modelo.

Objetivos Específicos

- OE1. Preprocesar las señales EEG para conservar sus propiedades no lineales y no estacionarias, eliminando ruido sin perder información relevante.
- OE2. Extraer características representativas de las señales EEG que permitan distinguir estado de estrés y no estrés de manera eficaz.
- OE3. Entrenar y validar un modelo SVM utilizando las características extraídas, optimizando sus parámetros para alcanzar alta precisión en la clasificación.

Metodología

1. Diseño de investigación

El proyecto adoptará un enfoque cuantitativo y experimental, orientado al desarrollo y evaluación de un clasificador SVM que será entrenado y validado utilizando datos preexistentes, bajo un esquema controlado que permitirá evaluar objetivamente su precisión y la preservación de las características inherentes de las señales EEG. La metodología se estructurará en etapas consecutivas de preprocesamiento, extracción de características y clasificación, con medición cuantitativa del desempeño.

2. Operacionalización de variables

Cuadro 1: Operacionalización de variables

Variable	Indicador	Técnica de medición
Precisión del clasificador	Porcentaje de aciertos en la clasificación de estrés vs relajación	Accuracy, precision, recall, F1-score
Preservación de la aleatoriedad y no estacionariedad de la señal EEG	Grado de conservación de propiedades dinámicas originales tras el preprocesamiento	Medición mediante entropía espectral antes, durante y después del procesamiento

3. Fuente de datos

Se utilizarán registros EEG provenientes del repositorio abierto “*EEG during mental arithmetic tasks*” de PhysioNet [9]. Las señales fueron registradas con el sistema Neurocom de 23 canales según el sistema internacional 10/20, y están disponibles en formato EDF. Cada sujeto cuenta con dos registros: uno en estado basal (relajado) y otro durante una tarea de aritmética mental (estresado). El conjunto incluye 36 participantes, divididos en dos grupos según el desempeño en la tarea: Grupo G (alto desempeño) y Grupo B (bajo desempeño). La clasificación binaria se establecerá para discriminar entre los estados de estrés y relajación. Se empleará el criterio de partición 80/20 para separar los datos en conjuntos de entrenamiento y prueba.

4. Preprocesamiento de señales EEG

Preparación de la información

Tras la descarga de los datos correspondientes a los estados de estrés y relajación, se llevó a cabo una inspección preliminar con el objetivo de evaluar la distribución de muestras en cada conjunto. Se identificó un desequilibrio considerable. El estado de relajación contiene 60 002

muestras por cada participante, mientras que el estado de estrés cuenta con 30 001 muestras por cada participante. Ambas señales fueron registradas con una frecuencia de muestreo de 500 Hz.

Con el objetivo de equilibrar ambos conjuntos y evitar sesgos en la fase de entrenamiento del modelo, se aplicará una técnica de escalamiento a las señales del conjunto minoritario. Esta consistirá en generar nuevas muestras mediante la multiplicación de las señales originales por un factor aleatorio comprendido entre 0.97 y 1.03, conservando así las características estadísticas y la aleatoriedad de la señal original. Finalmente, ambos conjuntos serán igualados a un total de 90 001 muestras por cada participante de cada conjunto.

Descomposición multiresolución

Para abordar la naturaleza no estacionaria y altamente compleja de las señales EEG, se empleará la Transformada Wavelet Discreta (DWT) utilizando como wavelet madre la función Daubechies de orden 4 (db4). Esta elección se sustentará en las propiedades que dicha wavelet ofrece para la descomposición multiresolución, como su suavidad y soporte compacto, lo que permitirá capturar transientes y patrones locales en la señal sin introducir distorsiones significativas [10].

La aplicación de la DWT permitirá descomponer cada canal en coeficientes de detalle (CD) y de aproximación (CA) hasta un total de 8 niveles. Esta descomposición facilitará la separación efectiva de los componentes de alta y baja frecuencia, conservando la estructura tiempo-frecuencia de la señal, fundamental para la preservación de su complejidad inherente.

Densidad Espectral de Potencia

Una vez obtenidos los coeficientes de aproximación y detalle mediante la Transformada Wavelet Discreta (DWT), se aplicará la Transformada Rápida de Fourier (FFT) con el objetivo de analizar su distribución espectral. Esta etapa permitirá identificar los componentes dominantes en el dominio de la frecuencia, complementando así el análisis multiresolución con una perspectiva frecuencial más precisa.

La aplicación de la FFT sobre los coeficientes de la DWT permitirá analizar la distribución de energía en el dominio de la frecuencia mediante la densidad espectral de potencia (PSD). Esta métrica es comúnmente utilizada para identificar patrones relevantes en señales EEG y detectar posibles anomalías asociadas a distintos niveles de activación cerebral [11].

Histograma de PSD

Como paso final antes de la extracción de características, se calculará el histograma de cada densidad espectral de potencia (PSD). Este análisis permitirá observar la distribución de los valores de potencia presentes en las señales, proporcionando información sobre la variabilidad y predominancia de ciertas magnitudes energéticas a lo largo del espectro.

5. Extracción de características

Una vez obtenido el histograma de la densidad espectral de potencia (PSD), se procederá con la extracción de características estadísticas, con base en el enfoque propuesto por [12]. Las características seleccionadas permitirán capturar distintas propiedades de la distribución espectral de la señal y son comúnmente utilizadas en el análisis de señales EEG por su relevancia fisiológica y robustez computacional. Las métricas extraídas serán las siguientes:

- **Mediana (\tilde{x}):** valor central de la distribución de potencia, robusto frente a valores atípicos.

$$\tilde{x} = \begin{cases} x_{(n+1)/2} & \text{si } n \text{ es impar} \\ \frac{1}{2}(x_{(n/2)} + x_{(n/2+1)}) & \text{si } n \text{ es par} \end{cases} \quad (1)$$

-
- **Raíz del valor cuadrático medio (RMS):** estimará la energía media de la señal, siendo sensible a valores de alta magnitud.

$$\text{RMS} = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \quad (2)$$

- **Curtosis (κ):** medirá la concentración de energía alrededor de la media, útil para detectar presencia de picos o eventos anómalos.

$$\kappa = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^4 \quad (3)$$

donde \bar{x} es la media y σ la desviación estándar.

- **Norma ($\|x\|_2$):** representará la magnitud total de la señal en el espacio euclíadiano.

$$\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2} \quad (4)$$

- **Entropía (H):** cuantificará la complejidad o aleatoriedad de la distribución de potencia, siendo útil para detectar señales caóticas o estructuradas.

$$H(x) = - \sum_{i=1}^n p_i \log_2(p_i) \quad (5)$$

donde p_i representa la probabilidad normalizada del valor x_i dentro del histograma.

Estas métricas serán calculadas sobre cada histograma PSD generado a partir de los coeficientes obtenidos en la etapa DWT, enriqueciendo así el vector de características que alimentará posteriormente el modelo de clasificación.

6. Clasificación de estados

Para la clasificación binaria de los estados de estrés y relajación, se empleará un clasificador SVM, entrenado utilizando distintos núcleos: lineal, radial base (RBF), polinomial y sigmoidal. Con el objetivo de maximizar el rendimiento del modelo, se aplicará el algoritmo PSO para la optimización de hiperparámetros.

PSO es una técnica de optimización poblacional inspirada en el comportamiento colectivo de enjambres, que permite realizar una búsqueda eficiente en espacios de soluciones de alta dimensionalidad [13]. En este contexto, los parámetros a optimizar incluyen el coeficiente de penalización C , el parámetro γ en kernels no lineales, y el grado del polinomio en el kernel polinomial.

El modelo SVM busca encontrar el hiperplano óptimo que maximice el margen entre clases, lo que puede formalizarse mediante el siguiente problema de optimización:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{sujeto a} \quad y_i (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (6)$$

donde \mathbf{w} es el vector de pesos, b es el sesgo, ξ_i son las variables de holgura que permiten cierta tolerancia a errores de clasificación, C controla el equilibrio entre la complejidad del modelo y el error, y $\phi(\cdot)$ representa la función de mapeo al espacio de características definido por el kernel.

En la Figura 1 se muestra el diagrama de la metodología propuesta.

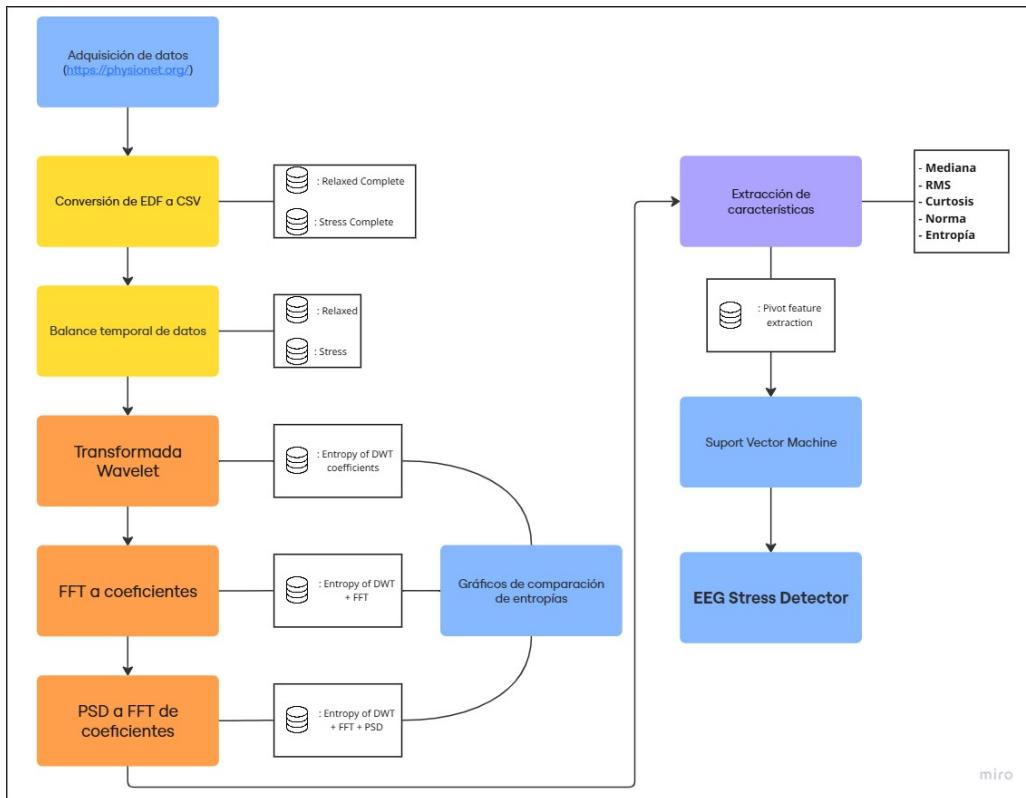


Figura 1: Diagrama de la metodología propuesta.

Estado del arte

La detección del estrés mediante señales electroencefalográficas (EEG) ha despertado un interés creciente en la investigación, dada su capacidad para reflejar cambios en la actividad cerebral asociados a diferentes estados emocionales. En este contexto, la combinación de técnicas de reducción de dimensionalidad, extracción de características espectrales y algoritmos de clasificación como el Support Vector Machine (SVM) se ha consolidado como una estrategia eficaz para mejorar la precisión y robustez de los modelos predictivos.

En [14] evaluaron el desempeño de dos técnicas clásicas de reducción de dimensionalidad, t-SNE y MDS, en conjunto con clasificadores como KNN, ENN y SVM sobre conjuntos de datos estándar. Sus resultados demostraron que la reducción dimensional mejora el rendimiento de los clasificadores, con SVM destacándose como un método robusto posterior a la transformación. Sin embargo, no se exploraron en profundidad las implicancias del aumento de datos ni la aplicabilidad en contextos de datos no lineales y ruidosos, como los EEG.

Por otro lado, en [7] compararon diferentes técnicas de análisis espectral como periodograma, método de Welch y multitaper para la extracción de características de señales EEG, evaluadas con un clasificador SVM. Además, aplicaron métodos de aumento de datos para incrementar artificialmente los vectores de características, logrando reducir el sobreajuste y aumentar la precisión, alcanzando un 96.16 % con el método de Welch. Este enfoque resalta la importancia del aumento de datos para mejorar la estabilidad del modelo, aunque sin discutir explícitamente los riesgos de introducir sesgos a partir de muestras artificiales.

La aplicación de análisis de bandas de frecuencia EEG para la detección de estrés fue validada por [15], quienes destacaron la validez del enfoque con SVM, pero también evidenciaron limitaciones derivadas de la homogeneidad de la muestra (solo hombres) y la presencia de interferencias como movimientos y parpadeos oculares. Estas limitaciones dificultan la generalización y estabilidad del clasificador, sin abordarse en detalle técnicas para mitigar el ruido o aumentar la muestra.

Un enfoque basado en transformada wavelet fue propuesto por [16] para extraer características relevantes en EEG de ratas bajo estrés térmico, empleando clasificadores SVM y redes neuronales RBF. Los autores enfatizan la necesidad de validar estos métodos en humanos y en condiciones reales, señalando las limitaciones que supone la generalización a partir de datos animales y la ausencia de técnicas de aumento de datos.

En [17] propusieron un modelo híbrido que combina clustering K-means con clasificación SVM para distinguir niveles de estrés en señales EEG. El clustering permite pre-etiquetar muestras basándose en su homogeneidad, mejorando la precisión final del SVM. Sin embargo, advierten que K-means es sensible a valores atípicos y ruido, lo cual puede introducir sesgos en la clasificación si no se manejan adecuadamente, enfatizando la importancia de un preprocesamiento riguroso.

La revisión sistemática realizada por [18] aborda el uso de técnicas de Data Augmentation (DA) para aprendizaje profundo con EEG. Se destacan los beneficios del aumento de datos para mejorar la precisión y reducir el sobreajuste, pero también se advierte sobre los riesgos asociados, tales como la alteración de las características temporales y espectrales originales de las señales, la generación de muestras irreales, la dificultad en el etiquetado correcto y la falta de métricas estandarizadas para evaluar la calidad de los datos aumentados. Estas limitaciones pueden comprometer la confiabilidad y generalización de los modelos.

Finalmente, en [19] presentan una revisión que clasifica diversas técnicas combinadas de DA, transferencia de aprendizaje y aprendizaje auto-supervisado para abordar la escasez de datos en EEG. Resaltan los retos de preservar la identidad de clase tras el aumento, evitar la introducción de ruido que degrada la señal y establecer métricas para validar la fidelidad de los datos aumentados. Subrayan la necesidad de incorporar enfoques multivariados y temporales que respeten la complejidad inherente de las señales EEG.

En síntesis, los avances revisados muestran que la reducción de dimensionalidad, combinada con métodos robustos como SVM, puede mejorar la clasificación de estrés en EEG. Sin embargo, el aumento de datos, aunque prometedor para mitigar la escasez de muestras y mejorar la estabilidad, requiere ser aplicado con precaución para evitar la introducción de sesgos y la pérdida de información relevante. Además, la heterogeneidad y ruido en las señales EEG demandan un preprocesamiento cuidadoso para asegurar la calidad de los datos y la generalización del modelo. Este marco orienta el presente trabajo a implementar un clasificador SVM que preserve la complejidad no lineal y no estacionaria de las señales EEG, evaluando críticamente el impacto del aumento de datos artificiales y la precisión robustez del sistema.

Ventajas y desventajas del proyecto

Cuadro 2: Análisis de ventajas y desventajas del proyecto

Categoría	Ventajas	Desventajas
Técnica	<ul style="list-style-type: none">■ El uso de SVM permite manejar relaciones no lineales en datos fisiológicos como EEG.■ La combinación de PSD e histogramas de PSD facilita una representación robusta de características espectrales.■ El modelo es interpretable y menos propenso al sobreajuste con entrenamiento adecuado.	<ul style="list-style-type: none">■ El desempeño del clasificador puede verse afectado por ruido o artefactos en las señales EEG.■ La elección de parámetros de PSD (ventana, resolución) influye fuertemente en la calidad de las características.■ Requiere una etapa previa de limpieza de datos precisa para resultados confiables.
Económico	<ul style="list-style-type: none">■ El uso de datos abiertos y previamente validados elimina costos asociados a la adquisición de información.■ Puede implementarse en dispositivos portátiles o de bajo consumo.	<ul style="list-style-type: none">■ La presencia de desequilibrio en las clases del conjunto de datos puede inducir sesgos en el modelo si no se realiza un análisis previo y un tratamiento adecuado..

Resultados y discusión

Con el objetivo de evitar la sobrecarga del presente artículo con la totalidad de los resultados gráficos individuales por sujeto, se ha seleccionado como ejemplo representativo al sujeto N.º 10 y al canal Fp2, el cual ha mostrado una de las mayores activaciones durante la ejecución de tareas complejas bajo restricciones temporales [20]. Los resultados completos, que incluyen gráficos, tablas y el código fuente, están disponibles en el repositorio de GitHub indicado en la sección de Anexos.

En primer lugar, se graficó la representación temporal de la señal EEG correspondiente al canal Fp2, tal como se muestra en la Figura 2. En esta visualización se evidencia la naturaleza altamente estocástica y no lineal de la actividad cerebral bajo ambas condiciones analizadas.

Posteriormente, se analizó la densidad espectral de potencia (PSD) de la señal sin aplicar procesamiento adicional. La Figura 3 revela que, en las frecuencias altas, la condición de *relajación* presenta una caída más pronunciada en comparación con la condición de *estrés*. No obstante, en las frecuencias bajas, la diferencia entre ambas condiciones resulta poco perceptible.

Como siguiente paso, se aplicó la transformada wavelet discreta (DWT) a la señal EEG del canal Fp2, utilizando la ondícula madre db4. Esta descomposición generó un coeficiente de aproximación (CA8) y ocho coeficientes de detalle (CD1–CD8). A cada uno de estos coefi-

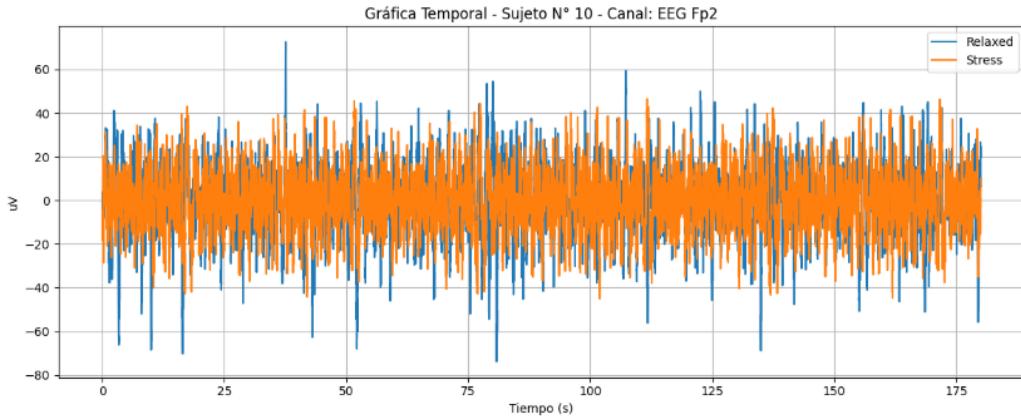


Figura 2: Representación temporal de la actividad EEG en el canal Fp2 del sujeto N° 10.

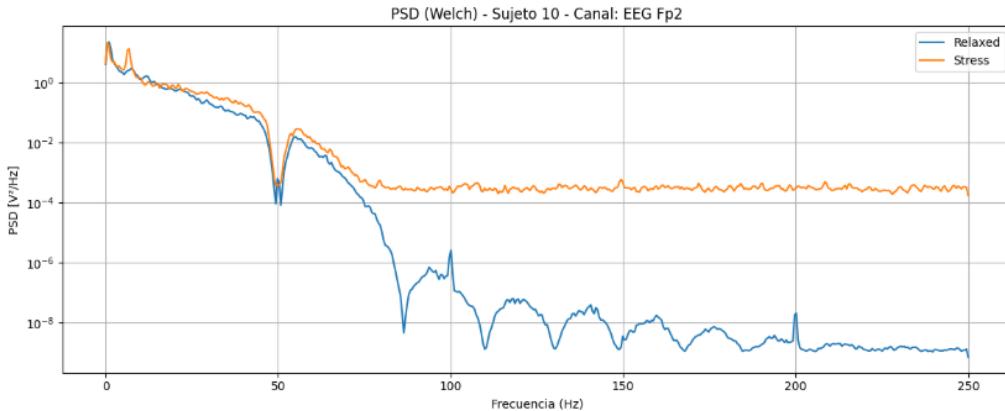


Figura 3: Distribución espectral de potencia de la señal EEG Fp2

cientes se le aplicó de forma individual la transformada rápida de Fourier (FFT), seguida del cálculo de su densidad espectral de potencia (PSD). Los resultados de la FFT se presentan en las Figuras [4, 5], mientras que los correspondientes al PSD se muestran en las Figuras [6, 7].

Las gráficas mencionadas reflejan un comportamiento coherente con lo observado en la Figura 3, donde las diferencias entre ambas condiciones son poco distinguibles en las frecuencias bajas, mientras que en las frecuencias altas se evidencian contrastes más marcados entre las clases.

Tras la aplicación de estas transformaciones, se procedió con la extracción de características a partir de la PSD. Este enfoque permitió analizar las señales en múltiples resoluciones, lo que enriqueció la información obtenida y mejoró el potencial discriminativo de las características utilizadas para el entrenamiento del clasificador basado en máquinas de soporte vectorial (SVM).

Dado que el objetivo principal del presente trabajo es entrenar una máquina de soporte vectorial (SVM) capaz de clasificar la presencia de estrés sin comprometer las propiedades estocásticas y no lineales inherentes a las señales EEG, se consideró fundamental aplicar transformaciones que, además de preservar dichas características, faciliten la organización y separación de la información en el espacio de características.

En este contexto, se llevó a cabo un análisis de la entropía en tres instancias sucesivas, con el fin de capturar la complejidad informacional de la señal en distintas etapas de procesamiento:

- **Entropía de coeficientes:** Calculada directamente sobre los coeficientes obtenidos mediante la transformada wavelet discreta (DWT) aplicada a la señal EEG del canal Fp2.
- **Entropía de FFT:** Calculada sobre los espectros generados al aplicar la transformada

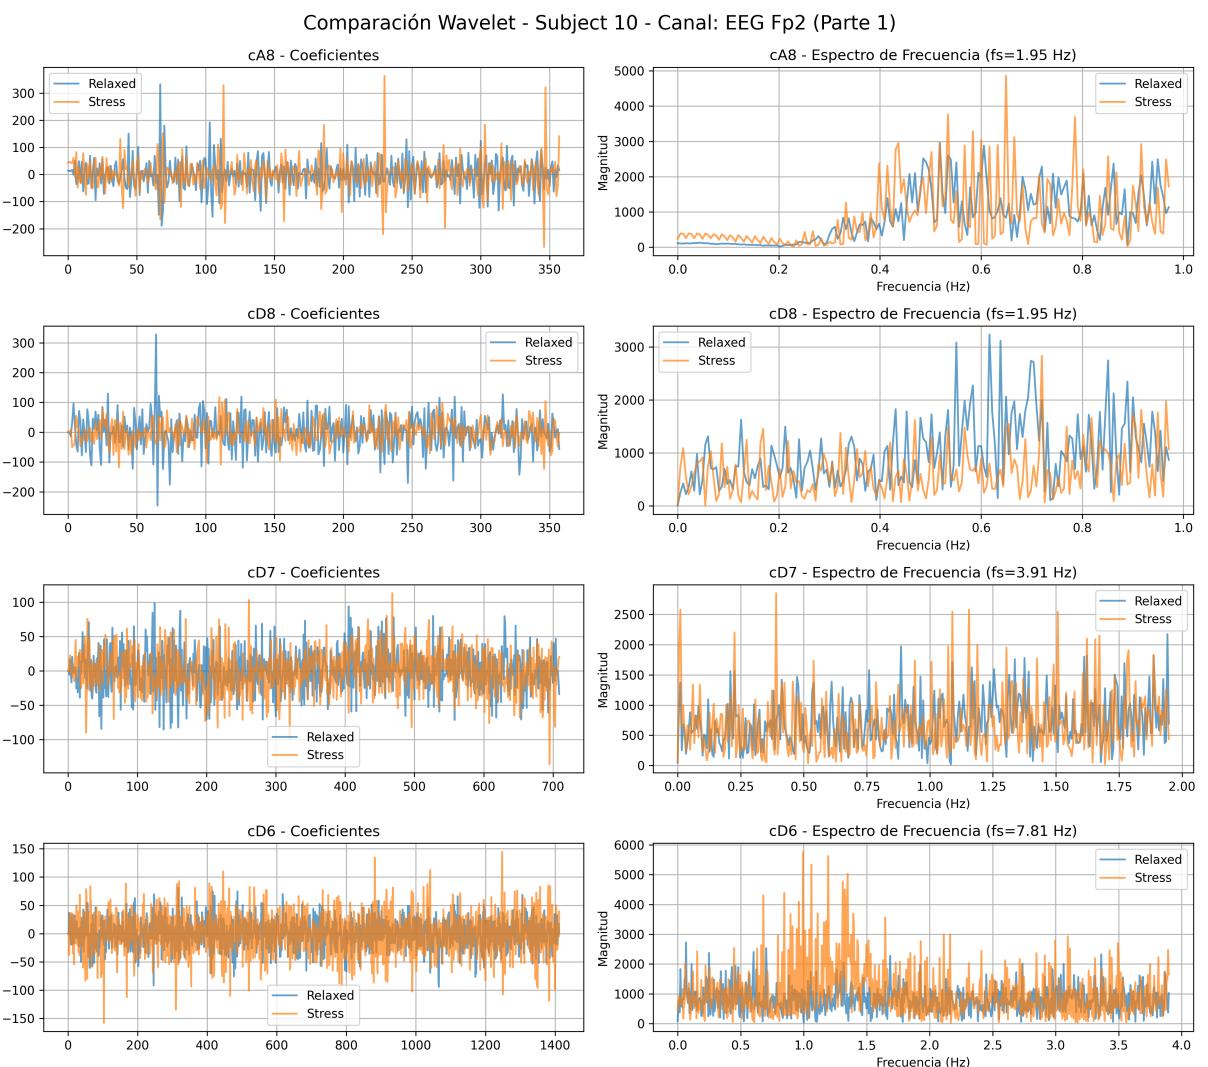


Figura 4: Coeficientes wavelet y su transformada de Fourier - Parte 1

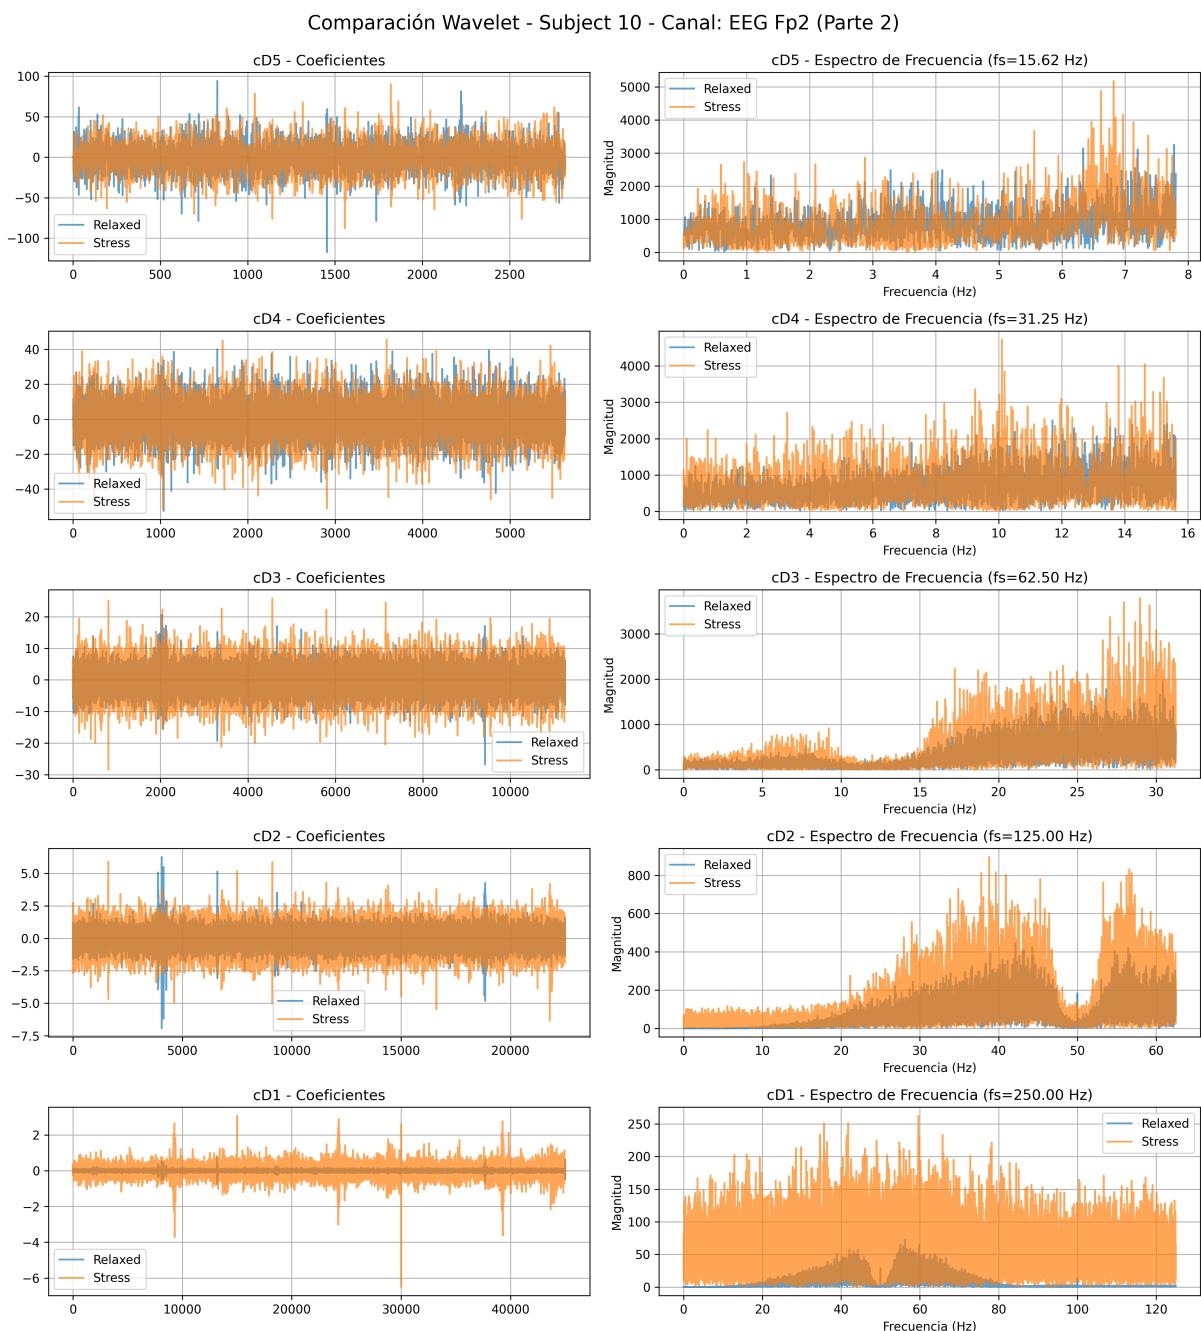


Figura 5: Coeficientes wavelet y su transformada de Fourier - Parte 2

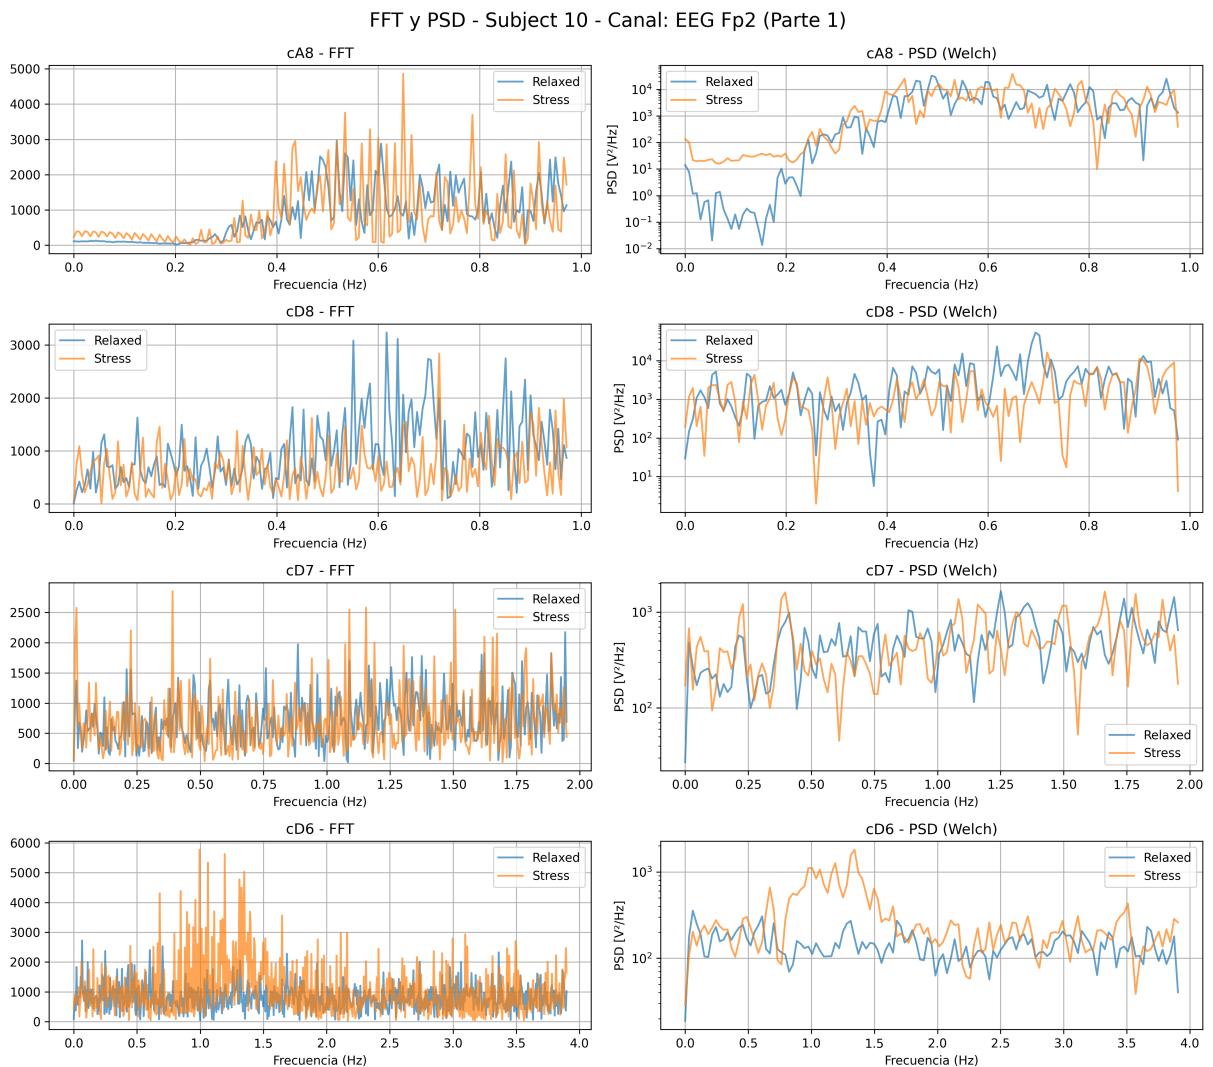


Figura 6: FFT de coeficientes wavelet y su PSD - Parte 1

FFT y PSD - Subject 10 - Canal: EEG Fp2 (Parte 2)

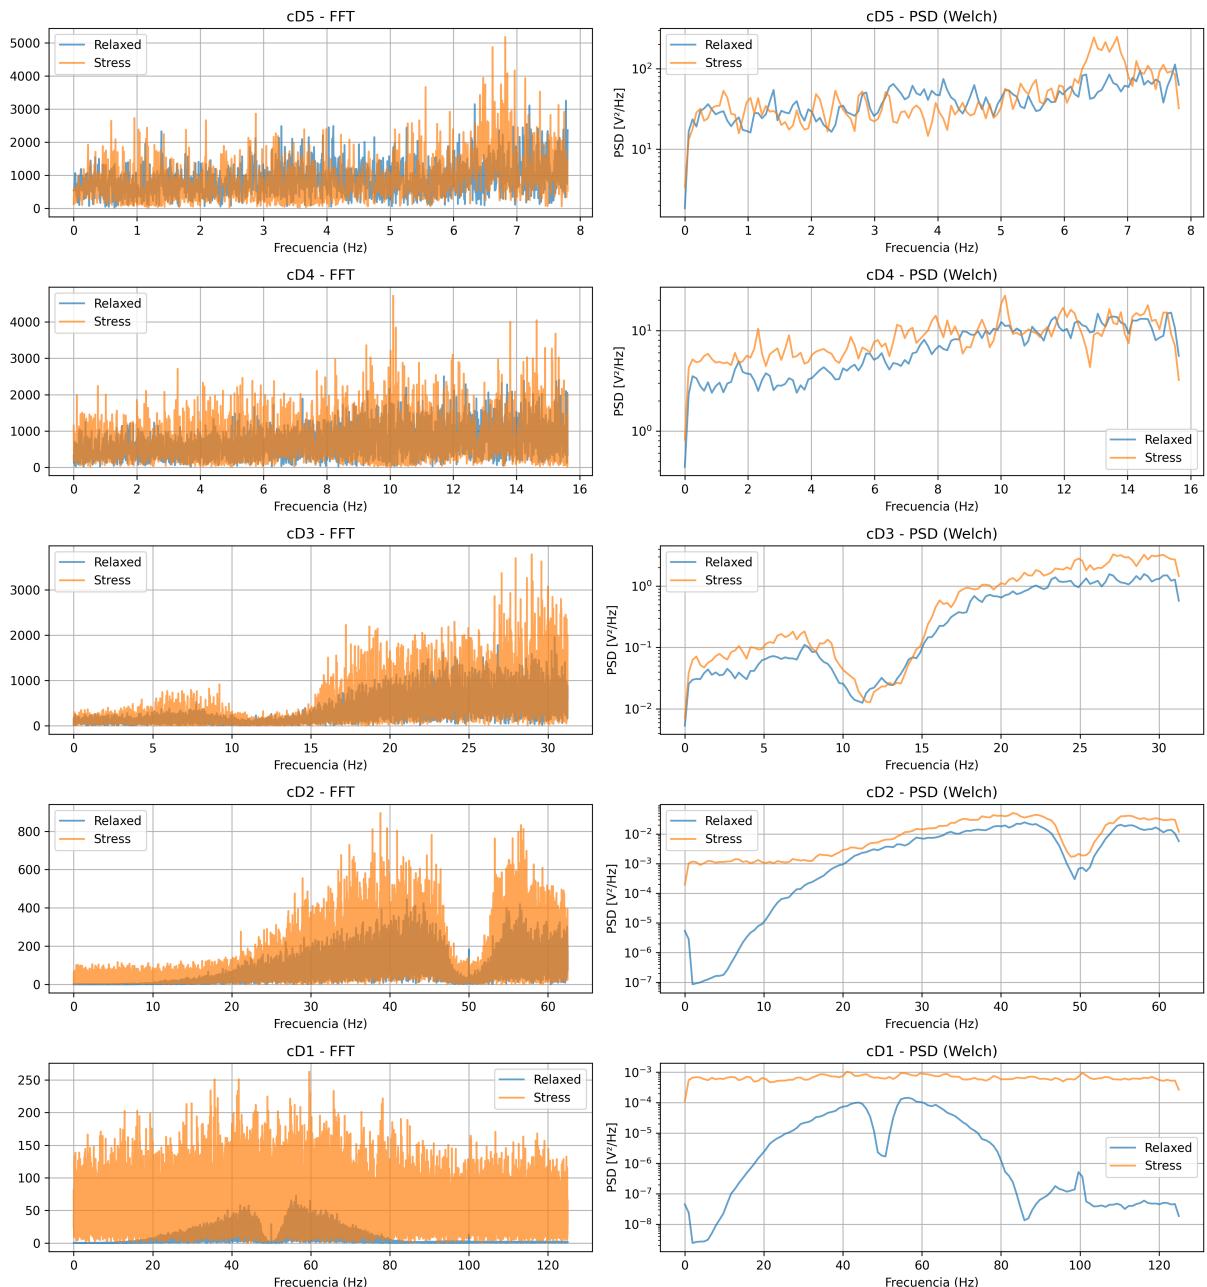


Figura 7: FFT de coeficientes wavelet y su PSD - Parte 2

rápida de Fourier (FFT) a cada conjunto de coeficientes DWT.

- **Entropía de PSD:** Calculada a partir de las distribuciones espectrales de potencia obtenidas mediante el método de Welch aplicado a los espectros FFT (DWT + FFT + PSD).

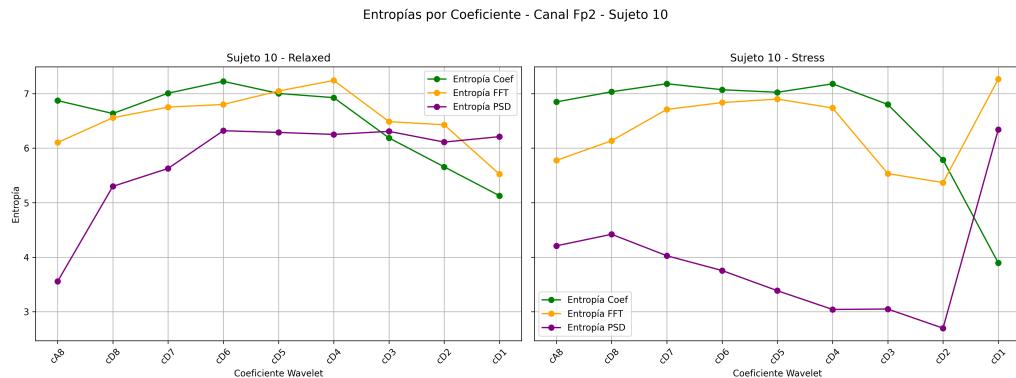


Figura 8: Comparación de entropías por cada coeficiente para el sujeto N°10 en el canal Fp2.

En la Figura 8 se ilustran los niveles de entropía obtenidos en cada una de las tres instancias de análisis, distribuidos por coeficiente wavelet. Esta representación permite identificar una característica clave con alto potencial discriminativo para la tarea de clasificación.

Se observa que, en los coeficientes correspondientes a las frecuencias bajas (CA8 hasta CD4), los sujetos en condición de relajación presentan niveles de entropía consistentemente más altos que aquellos en condición de estrés. Esta diferencia se atribuye a que las distribuciones de potencia en los sujetos estresados tienden a ser más uniformes o planas, es decir, con menores transiciones abruptas, lo que reduce la entropía medida. En contraste, los sujetos relajados muestran una mayor variabilidad en la distribución de potencia, reflejada en mayores niveles de entropía.

Estos patrones se corroboran en las Figuras 9, 10 y 11, correspondientes a las medidas de entropía calculadas sobre los coeficientes DWT, los espectros FFT y las distribuciones PSD, respectivamente.

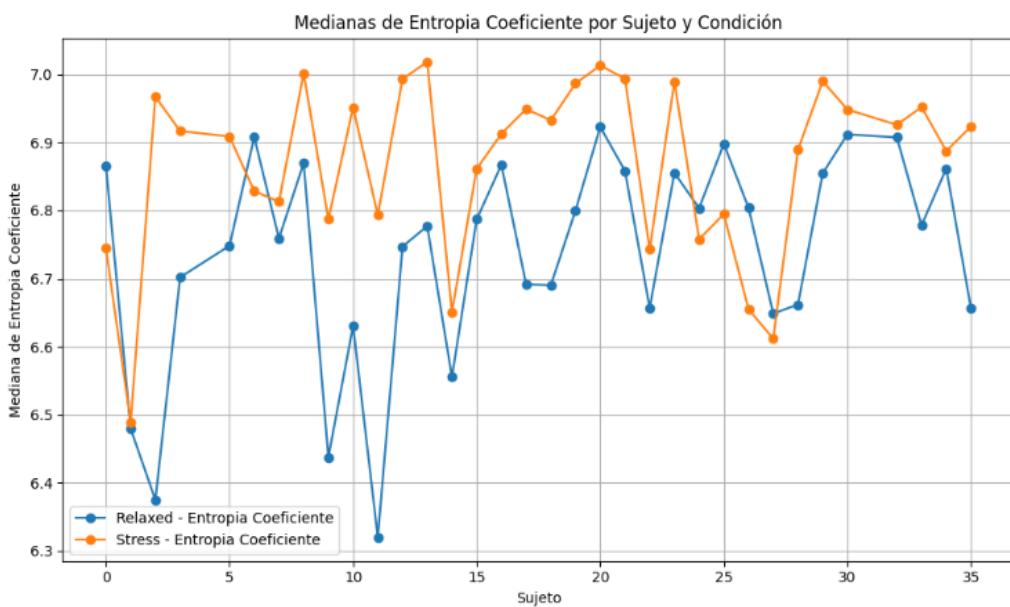


Figura 9: Comparación de medianas de entropías de coeficientes por cada sujeto.

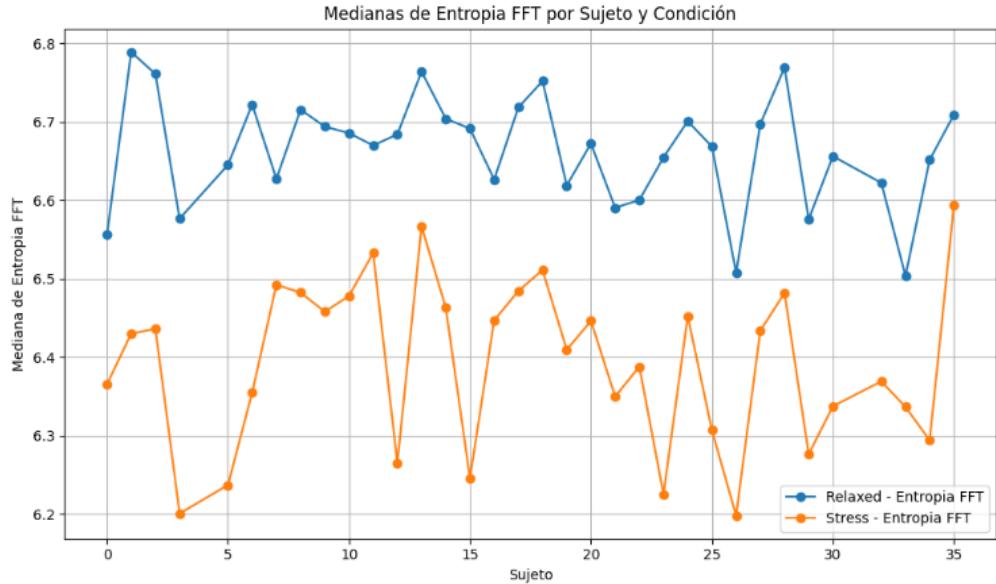


Figura 10: Comparación de medianas de entropías FFT por cada sujeto.

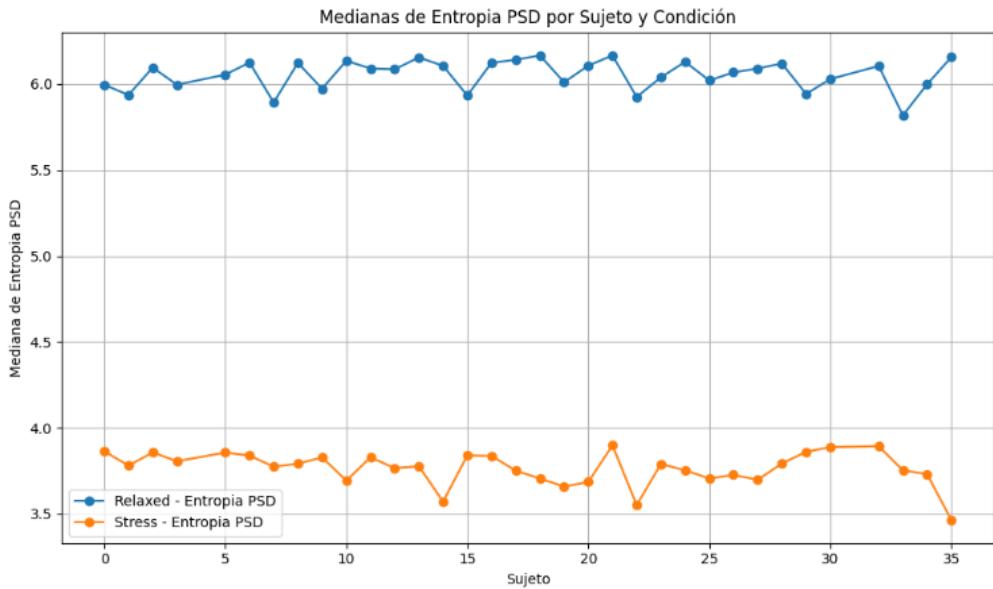


Figura 11: Comparación de medianas de entropías PSD por cada sujeto.

Finalmente, el modelo de clasificación fue entrenado utilizando cuatro tipos de kernel distintos, optimizando sus respectivos hiperparámetros mediante el algoritmo de Enjambre de Partículas (Particle Swarm Optimization, PSO). Los resultados obtenidos tras este proceso se resumen en la Tabla 3, donde se presentan las métricas de desempeño alcanzadas.

Cuadro 3: Desempeño del clasificador SVM según el tipo de kernel

Kernel	C	Gamma	Degree	Accuracy	F1	Prec.	Recall
Linear	16.68	scale	–	0.999	0.999	0.999	0.999
RBF	85.61	0.0001	–	0.999	0.999	0.999	0.999
Sigmoid	10.46	0.0001	–	0.999	0.999	0.999	0.999
Poly	3.98	0.3067	3	0.790	0.730	0.999	0.57

Conclusiones

En este estudio, se demostró que el clasificador basado en Máquinas de Vectores de Soporte (SVM) es una herramienta altamente eficaz para la detección de estrés en señales EEG, logrando resultados sobresalientes en la clasificación de los estados de estrés y relajación. Los resultados experimentales indicaron una precisión superior al 99 % para los diferentes tipos de núcleos empleados (lineal, RBF, polinomial y sigmoidal), lo que resalta la robustez y la capacidad de este modelo para manejar la clasificación binaria de forma precisa.

Un aspecto clave del análisis fue el uso de la entropía para diferenciar entre los estados de estrés y relajación. Se observó que los sujetos en estado de estrés presentaron niveles de entropía significativamente más bajos, lo cual indica una distribución de potencia más uniforme y menos variabilidad en las señales EEG. En cambio, los sujetos relajados mostraron niveles de entropía más elevados, lo que refleja una mayor variabilidad en las señales cerebrales. Esta diferencia en los niveles de entropía se ha establecido como una característica fundamental para la clasificación de los estados.

El enfoque adoptado en el preprocesamiento de las señales EEG, utilizando la Transformada Wavelet Discreta (DWT), permitió preservar las propiedades no lineales y no estacionarias de las señales, lo cual es esencial para no perder información fisiológica relevante durante el procesamiento. Este paso resultó ser crucial para asegurar que el modelo pudiera trabajar con señales que mantienen su complejidad inherente, fundamental para la precisión del clasificador.

La optimización de los hiperparámetros del clasificador mediante el uso de Enjambre de Partículas (PSO) también tuvo un impacto positivo en el desempeño del modelo, alcanzando métricas de desempeño casi perfectas, como precisión, recall y F1-score con un valor superior a 0,99 en comparación con las métricas obtenidas por [7]. Esta optimización permitió encontrar el mejor equilibrio entre la complejidad del modelo y el rendimiento, asegurando resultados consistentes.

A pesar de estos logros, el estudio también destacó algunas limitaciones relacionadas con la presencia de ruido y artefactos en las señales EEG. Estos factores pueden afectar la precisión del modelo, por lo que es esencial realizar un preprocesamiento riguroso para mitigar estos efectos. Además, el uso de técnicas de aumento de datos (data augmentation) puede introducir sesgos si no se maneja adecuadamente, lo que debe ser considerado en futuras investigaciones.

En términos de aplicaciones, el modelo SVM entrenado en este estudio puede ofrecer una herramienta valiosa para la detección objetiva de estrés, con aplicaciones potenciales tanto en entornos clínicos como en tecnológicos. El uso de señales EEG proporciona una forma directa y cuantificable de acceder al estado fisiológico del cerebro, lo que representa una mejora significativa frente a métodos tradicionales basados en autorreportes subjetivos. Esto sugiere que este enfoque podría contribuir a una mejor evaluación y diagnóstico del estrés en diversas áreas, como la salud mental, la medicina y el bienestar laboral.

Bibliografía

- [1] Organización Mundial de la Salud. "Estrés." (2025), dirección: <https://www.who.int/es/news-room/questions-and-answers/item/stress> (visitado 05-06-2025).
- [2] K. Kiuchi, X. Kang, R. Nishimura, M. Sasayama y K. Matsumoto, "Predicting physical and mental health status through interview-based evaluation of work stress: initial attempts to standardize the interviewing method," *Industrial Health*, vol. 62, n.º 4, págs. 237-251, 2024. DOI: 10.2486/indhealth.2023-0144.
- [3] Y. Badr, U. Tariq, F. Al-Shargie, F. Babiloni, F. Al Mughairbi y H. Al-Nashash, "A review on evaluating mental stress by deep learning using EEG signals," *Neural Computing and Applications*, vol. 36, n.º 21, págs. 12 629-12 654, 2024. DOI: 10.1007/s00521-024-09809-5.
- [4] S. Gedam y S. Paul, "A review on mental stress detection using wearable sensors and machine learning techniques," *IEEE Access*, vol. 9, págs. 84 045-84 066, 2021. DOI: 10.1109/ACCESS.2021.3085502.
- [5] S. S. Hosseini, M. Yamaghani y S. Poorzaker Arabani, "A review of methods for detecting multidimensional emotions in sound, image and text," *Journal of Applied Research on Industrial Engineering*, vol. 11, n.º 4, págs. 669-705, 2024, ISSN: 2538-5100. DOI: 10.22105/jarie.2024.413341.1560.
- [6] R. Fernandez-Matias, "El Cálculo del Tamaño Muestral en Ciencias de la Salud: Recomendaciones y Guía Práctica," *Journal of MOVE and Therapeutic Science*, vol. 5, n.º 1, págs. 481-503, 2023. DOI: 10.37382/jomts.v5i1.915.
- [7] H. Göker, *Comparison of different spectral analysis methods with an experimental EEG dataset*, 2022. DOI: 10.5281/zenodo.8070931. dirección: <https://doi.org/10.5281/zenodo.8070931>.
- [8] A. Sakai, Y. Minoda y K. Morikawa, "Data augmentation methods for machine-learning-based classification of bio-signals," en *2017 10th Biomedical Engineering International Conference (BMEiCON)*, 2017. DOI: 10.1109/BMEiCON.2017.8229109.
- [9] I. Zyma, S. Tukaev e I. Selezнов, *EEG during mental arithmetic tasks*, <https://physionet.org>, Accessed: 2025-06-05, 2018.
- [10] A. Rafiki et al., "Implementation of Vision Transformer for early detection of autism based on EEG signal heatmap visualization," *International Journal of Electrical, Electronics and Mechatronics Engineering (IJEEEEMI)*, vol. 7, n.º 1, págs. 102-112, 2025. DOI: 10.35882/40n05b64.
- [11] R. Wang, J. Wang, H. Yu, X. Wei, C. Yang y B. Deng, "Power spectral density and coherence analysis of Alzheimer's EEG," *Cognitive Neurodynamics*, vol. 9, n.º 3, págs. 291-304, 2015. DOI: 10.1007/s11571-014-9325-x.
- [12] K. AlSharabi, Y. Bin Salamah, A. M. Abdurraqeb, M. Aljalal y F. A. Alturki, "EEG signal processing for Alzheimer's disorders using discrete wavelet transform and machine learning approaches," *IEEE Access*, vol. 10, págs. 89 781-89 797, 2022. DOI: 10.1109/ACCESS.2022.3198988.
- [13] M. Daviran, A. Maghsoudi y R. Ghezelbash, "Optimized AI-MPM: Application of PSO for tuning the hyperparameters of SVM and RF algorithms," *Computers & Geosciences*, vol. 195, n.º 105785, pág. 105 785, 2025. DOI: 10.1016/j.cageo.2024.105785. dirección: <https://doi.org/10.1016/j.cageo.2024.105785>.
- [14] S. Sakib, M. A. B. Siddique y M. A. Rahman, *Performance Evaluation of t-SNE and MDS Dimensionality Reduction Techniques with KNN, ENN and SVM Classifiers*, arXiv preprint arXiv:2003.05138, 2020. arXiv: 2003.05138 [cs.LG]. dirección: <https://arxiv.org/abs/2003.05138>.

-
- [15] T. Waili, Y. S. Alshebly, K. A. Sidek y M. G. M. Johar, "Stress recognition using Electroencephalogram (EEG) signal," *Journal of Physics: Conference Series*, vol. 1502, n.º 1, pág. 012052, 2020. DOI: 10.1088/1742-6596/1502/1/012052.
 - [16] D. Dascalu. "Wavelet Based Performance Analysis of SVM and RBF Kernel for Classifying Stress Conditions of Sleep EEG." En línea. Disponible en: <https://www.romjist.ro/abstract-664.html> [Consultado: 06-jun-2025]. (2020).
 - [17] T. Y. Wen y S. A. M. Aris, "Hybrid approach of EEG stress level classification using K-means clustering and support vector machine," *IEEE Access*, vol. 10, págs. 18 370-18 379, 2022. DOI: 10.1109/ACCESS.2022.3148380.
 - [18] E. Lashgari, D. Liang y U. Maoz, "Data augmentation for deep-learning-based electroencephalography," *Journal of Neuroscience Methods*, vol. 346, n.º 108885, pág. 108 885, 2020. DOI: 10.1016/j.jneumeth.2020.108885.
 - [19] C. Ahuja y D. Sethia, "Harnessing Few-Shot Learning for EEG signal classification: a survey of state-of-the-art techniques and future directions," *Frontiers in Human Neuroscience*, vol. 18, pág. 1 421 922, 2024. DOI: 10.3389/fnhum.2024.1421922.
 - [20] B. González-Gómez, M. I. Núñez-Peña y Colomé, "Math anxiety and the shifting function: An event-related potential study of arithmetic task switching," *European Journal of Neuroscience*, vol. 57, n.º 11, págs. 1848-1869, 2023. DOI: 10.1111/ejn.15958.

Anexos

Repositorio de Código

El código fuente completo, incluyendo gráficos, tablas y scripts utilizados en este estudio, se encuentra disponible en el siguiente repositorio de GitHub:

<https://github.com/rnloz26/StressDetectorProject.git>